

# PROPOSAL SKRIPSI

## Optimasi Model *Machine Learning* dan *Quantum Machine Learning* untuk Prakiraan Cuaca di Indonesia



DISUSUN OLEH  
ADI SAPUTRA  
220322601412

KBK KOMPUTASI DAN TEORITIK

DOSEN PEMBIMBING

Dr. Eny Latifah S.Si, M.Si

NIP 196907311998022001

Dr. Ahmad Ridwan Tresna Nugraha

NIP 198709202019021002

UNIVERSITAS NEGERI MALANG  
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM  
PROGRAM STUDI FISIKA  
NOVEMBER 2025

## **LEMBAR PERSETUJUAN PEMBIMBING PROPOSAL SKRIPSI**

Proposal Skripsi oleh Adi Saputra ini telah diperiksa dan disetujui untuk diuji.

Malang, 14 November 2025

Pembimbing I

Dr. Eny Latifah, S.Si., M.Si  
NIP 196907311998022001

Pembimbing II

Dr. Ahmad Ridwan Tresna Nugraha  
NIP 198709202019021002

## RINGKASAN

Saputra, Adi. 2025. Optimasi Model Machine Learning dan Quantum Machine Learning untuk Prakiraan Cuaca di Indonesia. Skripsi, Departemen Fisika, Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Negeri Malang. Pembimbing: (I) Dr. Eny Latifah, S.Si., M.Si (II) Dr. Ahmad Ridwan Tresna Nugraha. Prakiraan cuaca yang akurat, khususnya curah hujan total (*total precipitation*), merupakan komponen krusial bagi mitigasi bencana dan ketahanan pangan di Indonesia, namun tetap menjadi salah satu tantangan komputasi tersulit akibat sifat atmosfer yang kompleks, non-linear, dan kacau. Pendekatan *machine learning* (ML) klasik yang ada saat ini masih menghadapi keterbatasan dalam melakukan generalisasi terhadap kejadian cuaca ekstrem. *Quantum machine learning* (QML) muncul sebagai paradigma baru yang menjanjikan, menawarkan keunggulan teoretis melalui pemetaan data ke ruang fitur kuantum berdimensi eksponensial untuk menangkap korelasi yang lebih rumit. Meskipun beragam arsitektur QML seperti *Quantum Support Vector Regression* (QSVR), *Quantum Neural Network* (QNN), dan *Quantum Long Short-Term Memory* (QLSTM) telah diusulkan, terdapat kesenjangan riset mengenai studi perbandingan (*benchmarking*) sistematis atas performa ketiganya pada data meteorologi dunia nyata yang kompleks. Fokus penelitian ini adalah untuk mengisi kesenjangan tersebut. Tujuan dari penelitian ini adalah untuk melakukan analisis perbandingan komprehensif terhadap tiga paradigma utama QML (berbasis kernel, variasional, dan rekuren) untuk tugas prakiraan curah hujan. Metode penelitian ini dirancang sebagai studi eksperimen komputasi kuantitatif. Data historis 5 tahun (2020-2024) bersumber dari dataset ERA5 (reanalysis-era5-single-levels) dengan resolusi 6 jam untuk wilayah Indonesia. Vektor fitur input terdiri dari 12 variabel, mencakup 8 prekursor fisik meteorologi (suhu, tekanan, uap air, angin, dll.) serta fitur lag dan temporal, untuk memprediksi variabel target total precipitation. Model klasik (SVR, LSTM) dan kuantum (QSVR, QNN, QLSTM) diimplementasikan dalam kerangka hibrida kuantum-klasik menggunakan

Qiskit. Model dievaluasi pada simulator kuantum (qiskit-aer) dan divalidasi pada perangkat keras kuantum IBM. Analisis performa didasarkan pada metrik *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan Koefisien Determinasi ( $R^2$ ). Posisi penelitian ini adalah sebagai studi *benchmarking* empiris yang mengevaluasi kelayakan dan efektivitas arsitektur QML utama pada dataset prakiraan cuaca yang sama, guna memberikan wawasan berbasis bukti mengenai arsitektur yang paling menjanjikan serta robustitasnya terhadap *noise* pada perangkat keras era NISQ.

Kata kunci: Pembelajaran Mesin Kuantum, Prakiraan Curah Hujan, Analisis Komparatif, QSVR, QLSTM

## DAFTAR ISI

|                                                           |          |
|-----------------------------------------------------------|----------|
| RINGKASAN .....                                           | ii       |
| DAFTAR ISI .....                                          | iv       |
| DAFTAR GAMBAR .....                                       | vi       |
| DAFTAR TABEL.....                                         | vii      |
| <b>BAB I    PENDAHULUAN.....</b>                          | <b>1</b> |
| A.    Latar Belakang .....                                | 1        |
| B.    Rumusan Masalah .....                               | 3        |
| C.    Hipotesis Penelitian.....                           | 4        |
| D.    Manfaat Penelitian.....                             | 5        |
| E.    Ruang Lingkup Penelitian .....                      | 5        |
| F.    Definisi Operasional .....                          | 7        |
| <b>BAB II    TINJAUAN PUSTAKA .....</b>                   | <b>8</b> |
| A.    Prinsip Dasar Komputasi Kuantum .....               | 8        |
| A.1    Qubit, Superposisi, dan Keterbelitan .....         | 8        |
| A.2    Gerbang Kuantum Dasar .....                        | 8        |
| B. <i>Quantum Machine Learning</i> .....                  | 9        |
| C. <i>Support Vector Regression</i> (SVR) .....           | 10       |
| D.    Model Kuantum Berbasis Kernel.....                  | 10       |
| D.1    Quantum Feature Map.....                           | 10       |
| D.2    Kernel Kuantum.....                                | 11       |
| D.3 <i>Quantum Support Vector Regression</i> (QSVR) ..... | 12       |
| E.    Model Kuantum Berbasis Sirkuit Variasional .....    | 12       |
| E.1 <i>Quantum Neural Network</i> (QNN) .....             | 12       |
| E.2 <i>Quantum Long Short-Term Memory</i> (QLSTM) .....   | 13       |

|                                            |           |
|--------------------------------------------|-----------|
| <b>BAB III METODOLOGI PENELITIAN .....</b> | <b>14</b> |
| A. Rancangan Penelitian .....              | 14        |
| B. Tempat dan Waktu Penelitian .....       | 15        |
| B.1 Tempat.....                            | 15        |
| B.2 Waktu.....                             | 15        |
| C. Prosedur Penelitian .....               | 16        |
| C.1 Prapemrosesan Data .....               | 16        |
| C.2 Implementasi dan Pelatihan Model ..... | 16        |
| C.3 Evaluasi dan Analisis Komparatif ..... | 18        |
| <b>DAFTAR PUSTAKA .....</b>                | <b>18</b> |

## DAFTAR GAMBAR

|     |                                                                                                                                                        |    |
|-----|--------------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 2.1 | Representasi visual sirkuit kuantum ZZFeatureMap.....                                                                                                  | 11 |
| 2.2 | Representasi visual QNN.....                                                                                                                           | 13 |
| 3.1 | Diagram alir rancangan penelitian. ....                                                                                                                | 14 |
| 3.2 | Representasi visual sirkuit kuantum ZZFeatureMap. Arsitektur ini digunakan sebagai dasar untuk <i>quantum feature map</i> pada model QSVR dan QNN..... | 17 |

## DAFTAR TABEL

|     |                                                |    |
|-----|------------------------------------------------|----|
| 2.1 | Gerbang kuantum dasar yang umum digunakan..... | 9  |
| 3.1 | Jadwal kegiatan penelitian .....               | 15 |

# BAB I

## PENDAHULUAN

### A. Latar Belakang

Prakiraan cuaca yang akurat dan tepat waktu merupakan komponen krusial dalam masyarakat modern, dengan dampak signifikan terhadap berbagai sektor mulai dari manajemen energi, pertanian, transportasi, hingga mitigasi bencana alam [1, 2]. Bagi negara maritim tropis seperti Indonesia, salah satu parameter paling krusial dan menantang untuk diprediksi adalah curah hujan. Akan tetapi, memprediksi fenomena atmosfer adalah salah satu tantangan komputasi paling sulit [3, 4]. Hal ini disebabkan oleh sifat dasar sistem atmosfer yang sangat kompleks, non-linear, dan kacau (*chaotic*), yang secara inheren membatasi akurasi prediksi, terutama untuk prakiraan jangka menengah hingga panjang [3, 5].

Pentingnya prakiraan curah hujan total (*total precipitation*) di Indonesia tidak dapat dilebih-lebihkan. Variabel ini merupakan variabel target yang menjadi pemicu utama bencana hidrometeorologi seperti banjir dan tanah longsor, sekaligus menjadi penentu vital bagi ketahanan pangan di sektor pertanian melalui manajemen irigasi dan prediksi kekeringan. Secara ilmiah, curah hujan juga merupakan salah satu variabel yang paling sulit dimodelkan karena sifatnya yang sangat stokastik (acak) dan variasinya yang tinggi dalam ruang dan waktu.

Prakiraan curah hujan yang akurat bergantung pada kemampuan model untuk memahami interaksi fisik yang kompleks dari berbagai prekursor (pendorong) di atmosfer. Presipitasi bukanlah fenomena yang terisolasi; formasinya adalah hasil akhir dari sebuah proses dinamis. Proses ini sangat bergantung pada ketersediaan "bahan bakar" berupa uap air di atmosfer, yang diukur oleh *total column water vapour* (TCWV) dan *evaporation*. Selain itu, proses kondensasi dan pembentukan awan sangat dikontrol oleh kondisi termodinamika seperti suhu (*2m temperature*) dan titik embun (*2m dewpoint temperature*). Terakhir, mekanisme pengangkatan massa udara yang memicu hujan lebat sangat dipengaruhi oleh dinamika pergerakan

angin (*wind components*) dan sistem tekanan di permukaan (*mean sea level pressure*). Oleh karena itu, model prakiraan yang andal harus mampu memproses dan mengekstrak korelasi non-linear yang rumit antara semua variabel prediktor fisik ini.

Seiring dengan peningkatan volume data, pendekatan berbasis pembelajaran mesin atau *machine learning* (ML) telah menjadi alat yang menunjukkan kemampuan unggul dalam menangkap hubungan multi-variat ini [6, 7]. Model seperti *support vector regression* (SVR) secara spesifik cukup efektif untuk tugas peramalan, khususnya dalam memprediksi curah hujan [8, 9]. Namun, model ML klasik yang paling canggih sekalipun masih menghadapi tantangan dalam generalisasi fenomena pada kondisi cuaca ekstrem yang jarang terjadi, yang seringkali merupakan data *outlier* [5, 3]. Keterbatasan ini mendorong eksplorasi paradigma komputasi baru untuk menemukan solusi yang lebih kokoh.

*Quantum machine learning* (QML) baru-baru ini muncul sebagai bidang interdisipliner yang menjanjikan, dengan memanfaatkan prinsip-prinsip mekanika kuantum seperti superposisi dan keterbelitan (*entanglement*) untuk memproses informasi dengan cara yang secara fundamental berbeda [10, 11]. Keunggulan utama QML terletak pada kemampuannya untuk memetakan data klasik ke dalam ruang kuantum (ruang Hilbert) yang dimensinya tumbuh secara eksponensial [12]. Pemetaan ke dalam ruang fitur yang lebih besar ini secara teoretis mampu menangkap korelasi dan pola data yang jauh lebih rumit seperti hubungan antar-variabel meteorologi yang berpotensi tidak dapat diakses oleh metode-metode klasik [13, 14].

Perkembangan penelitian QML telah menghasilkan beberapa kelas model yang menjanjikan untuk aplikasi di era *Noisy Intermediate-Scale Quantum* (NISQ) saat ini [15]. Era ini ditandai oleh ketersediaan perangkat keras kuantum yang masih rentan terhadap berbagai sumber galat atau *noise*, yang dapat memengaruhi akurasi komputasi. Salah satu pendekatan QML yang matang adalah metode berbasis kernel kuantum, yang diimplementasikan dalam *quantum support vector regression* (QSVR) [16, 17]. Pendekatan ini menggunakan sirkuit kuantum yang disebut *Quantum Feature Map* untuk menyandikan data ke dalam keadaan kuantum, lalu menghitung "kemiripan" antar data untuk membentuk kernel yang diolah oleh SVR klasik. Alternatifnya adalah pendekatan variasional,

seperti pada *quantum neural network* (QNN), yang menggunakan Sirkuit Kuantum Variasional (VQC) sebagai model yang dapat dilatih [18, 5]. Dalam VQC, parameter-parameter sirkuit dioptimalkan secara iteratif, dan hasil prediksi diekstrak melalui pengukuran nilai ekspektasi dari sebuah *Observable* [19]. Untuk data deret waktu, arsitektur *quantum long short-term memory* (QLSTM) mengadaptasi pendekatan VQC ini dengan menggantikan komponen internal LSTM klasik dengan sirkuit kuantum untuk menangkap dependensi temporal dengan lebih efisien [20, 21, 22].

Meskipun ketiga pendekatan QML ini (QSVR, QNN, dan QLSTM) telah menunjukkan potensi pada berbagai masalah, masih terdapat celah dalam pemahaman mengenai performa komparatif mereka pada tugas yang sama, terutama pada data meteorologi dunia nyata yang memiliki variabilitas tinggi. Saat ini, belum ada konsensus mengenai arsitektur QML mana yang paling cocok untuk menangani dinamika kompleks dalam data curah hujan. Oleh karena itu, diperlukan sebuah studi komparasi atau *benchmarking* yang sistematis untuk mengevaluasi keunggulan dan kelemahan dari masing-masing pendekatan ini [21].

Penelitian ini berfokus untuk mengisi celah tersebut dengan melakukan analisis perbandingan komprehensif antara model QSVR, QNN, dan QLSTM untuk tugas prakiraan curah hujan. Posisi penelitian ini adalah sebagai studi kasus empiris yang mengimplementasikan dan mengevaluasi tiga paradigma utama QML pada himpunan data meteorologi yang sama. Dengan melakukan *benchmark*, penelitian ini bertujuan untuk memberikan wawasan berbasis bukti mengenai arsitektur QML mana yang paling menjanjikan, serta mengidentifikasi kondisi di mana setiap model dapat menunjukkan keunggulannya, termasuk ketahanannya terhadap *noise* pada perangkat keras kuantum nyata. Hasilnya diharapkan akan berkontribusi pada kerangka kerja *quantum-improved weather forecast* (QWF) yang lebih luas [23], dengan memberikan panduan praktis dalam merancang model QML yang efektif untuk meningkatkan akurasi prakiraan cuaca di masa depan.

## B. Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, penelitian ini bertujuan untuk menjawab pertanyaan-pertanyaan berikut:

1. Apa saja *Trade-off* yang ada antara model QML dalam hal kompleksitas model (jumlah parameter, kedalaman sirkuit) dan beban komputasi untuk pelatihan dan inferensi?
2. Bagaimana performa akurasi antara tiga paradigma arsitektur *quantum machine learning* berbasis kernel (QSVR), variasional (QNN), dan rekuren (QLSTM) dibandingkan satu sama lain terhadap baseline ML klasik pada kasus cuaca?
3. Seberapa efektif model-model QML tersebut dalam menangkap dinamika non-linear dan kejadian ekstrem pada data deret waktu meteorologi, dan bagaimana performa mereka saat divalidasi pada perangkat keras kuantum nyata yang memiliki *noise*?

### C. Hipotesis Penelitian

Sebagai jawaban tentatif atas rumusan masalah, berikut adalah hipotesis yang akan diuji dalam penelitian ini:

1. Model QML, khususnya yang secara inheren dirancang untuk data sekuensial, akan menunjukkan akurasi prediksi (diukur dengan *Root Mean Square Error* (RMSE) yang lebih rendah) yang secara signifikan lebih unggul dibandingkan model QSVR, QNN, dan baseline klasik.
2. Kemampuan model QML untuk memetakan data ke ruang fitur kuantum berdimensi tinggi akan membuatnya lebih efektif dalam menangkap kejadian curah hujan ekstrem dibandingkan model klasik. Kinerja unggul ini akan tetap terjaga (*robust*) saat divalidasi pada perangkat keras kuantum nyata, meskipun dengan potensi penurunan akurasi akibat *noise*.
3. Model kuantum variasional seperti QNN dan QLSTM akan mampu mencapai performa yang kompetitif atau bahkan superior dengan jumlah parameter terlatih yang lebih sedikit dibandingkan model klasik yang setara, meskipun dengan beban komputasi yang lebih tinggi pada tahap inferensi dan pelatihan.

#### D. Manfaat Penelitian

Hasil dari penelitian ini diharapkan dapat memberikan manfaat teoretis dan praktis sebagai berikut:

##### Manfaat Teoretis

1. Menyediakan salah satu studi *benchmarking* sistematis pertama yang membandingkan tiga paradigma arsitektur QML yang berbeda (kernel, variasional, dan rekuren) pada data meteorologi dunia nyata.
2. Berkontribusi pada pemahaman komunitas ilmiah mengenai kekuatan, kelemahan, dan kondisi optimal untuk setiap jenis arsitektur QML dalam menangani data deret waktu yang kompleks.
3. Menyajikan data empiris mengenai perbandingan model-model QML terhadap *noise* dari perangkat keras kuantum era NISQ, yang sangat penting untuk menilai kelayakan praktisnya.

##### Manfaat Praktis

1. Membuka jalur potensial untuk pengembangan model prakiraan cuaca generasi baru yang lebih akurat, yang dapat berdampak langsung pada peningkatan sistem mitigasi bencana.
2. Memberikan panduan bagi para praktisi dan peneliti dalam memilih dan merancang model QML yang paling sesuai untuk masalah peralaman deret waktu kompleks lainnya diluar bidang meteorologi, seperti bidang finansial atau kesehatan.

#### E. Ruang Lingkup Penelitian

Penelitian ini dibatasi pada beberapa aspek untuk menjaga fokus dan kedalaman analisis agar sesuai dengan permasalahan yang diangkat. Ruang lingkup penelitian ini adalah sebagai berikut:

##### Batasan pada Lingkup Data

1. Penelitian ini secara eksklusif menggunakan data dari dataset reanalysis-era5-single-levels, yang diakses melalui Copernicus Climate

Data Store (CDS) dari *European Centre for Medium-Range Weather Forecasts* (ECMWF).

2. Cakupan geografis data dibatasi pada wilayah Indonesia dan sekitarnya, dengan koordinat area  $[6^{\circ} \text{ LU}, 95^{\circ} \text{ BT}, -11^{\circ} \text{ LS}, 141^{\circ} \text{ BT}]$ .
3. Data yang digunakan mencakup rentang waktu 5 tahun, dari 1 Januari 2020 hingga 31 Desember 2024, dengan resolusi temporal 6 jam.
4. Fitur prediktor yang digunakan terdiri dari 8 variabel meteorologi dari dataset ERA5 *10m u component of wind*, *10m v component of wind*, *2m dewpoint temperature*, *2m temperature*, *mean sea level pressure*, *total precipitation*, *evaporation*, dan *total column water vapour*, ditambah dengan fitur turunan berupa fitur lag dan temporal.
5. Variabel target yang akan diprediksi adalah total presipitasi *total precipitation*.

#### **Batasan pada Implementasi Kuantum:**

1. Seluruh eksperimen model kuantum dijalankan pada simulator kuantum klasik (qiskit-aer) dan divalidasi pada perangkat keras kuantum nyata milik IBM yang tersedia melalui cloud.
2. Karena menggunakan simulator ideal sebagai pembanding utama, penelitian ini tidak menganalisis secara mendalam dampak kuantitatif dari berbagai jenis *noise* yang ada pada perangkat keras kuantum era NISQ.
3. Teknik mitigasi error kuantum tidak diimplementasikan dan diusulkan sebagai bagian dari penelitian lanjutan.

#### **Batasan pada Metodologi:**

1. Studi kasus utama membandingkan tiga arsitektur QML spesifik yaitu QSVR dengan ZZFeatureMap dan PauliFeatureMap, QNN dengan arsitektur variasional, dan QLSTM. Analisis mendalam terhadap semua kemungkinan arsitektur lain berada di luar cakupan penelitian ini.

2. Tujuan utama penelitian adalah sebagai studi komparatif untuk mengevaluasi kelayakan dan potensi performa dari paradigma-paradigma QML tersebut, dan tidak bertujuan untuk membangun sebuah model prakiraan cuaca yang siap pakai secara operasional.

## F. Definisi Operasional

Untuk memberikan pemahaman yang seragam, berikut adalah definisi operasional dari beberapa istilah kunci yang digunakan dalam penelitian ini:

1. *Sirkuit Kuantum Variasional (VQC) / Ansatz*: Merujuk pada sirkuit kuantum yang memiliki parameter-parameter rotasi yang dapat dilatih ( $\theta$ ). Dalam penelitian ini, VQC berfungsi sebagai lapisan “terlatih” pada model QNN dan QLSTM, di mana parameter-parameternya dioptimalkan untuk meminimalkan fungsi biaya.
2. *Observable*: Merujuk pada operator Hermitian ( $\hat{M}$ ) yang diaplikasikan pada akhir sirkuit QNN/QLSTM. Nilai ekspektasi dari *observable* inilah yang diukur dan dijadikan sebagai output numerik dari model kuantum variasional.
3. *Noise*: Dalam konteks penelitian ini, merujuk pada berbagai sumber galat (*error*) yang melekat pada perangkat keras kuantum era NISQ, seperti galat gerbang (*gate error*) dan dekoherensi, yang menyebabkan hasil komputasi pada perangkat keras nyata menyimpang dari hasil simulasi ideal.

## BAB II

### TINJAUAN PUSTAKA

#### A. Prinsip Dasar Komputasi Kuantum

Komputasi kuantum adalah paradigma komputasi yang memanfaatkan fenomena dari mekanika kuantum untuk memproses informasi. Berbeda dengan komputasi klasik yang mengandalkan bit sebagai unit informasi, komputasi kuantum menggunakan qubit.

##### A.1 Qubit, Superposisi, dan Keterbelitan

Qubit adalah unit dasar informasi dalam komputasi kuantum. Serupa dengan bit klasik yang dapat berada dalam keadaan 0 atau 1, qubit juga memiliki keadaan dasar, yang dilambangkan dengan  $|0\rangle$  dan  $|1\rangle$ . Namun, berkat prinsip superposisi, sebuah qubit dapat eksis dalam kombinasi linear dari kedua keadaan dasar tersebut secara bersamaan. Keadaan superposisi sebuah qubit ( $|\psi\rangle$ ) dapat ditulis sebagai:

$$|\psi\rangle = \alpha |0\rangle + \beta |1\rangle \quad (2.1)$$

di mana  $\alpha$  dan  $\beta$  adalah amplitudo probabilitas kompleks yang memenuhi syarat  $|\alpha|^2 + |\beta|^2 = 1$ .

Fenomena fundamental lainnya adalah keterbelitan (*entanglement*), di mana keadaan dua atau lebih qubit saling terhubung secara non-lokal. Jika dua qubit terbelit, pengukuran pada salah satu qubit akan secara instan memengaruhi keadaan qubit lainnya, tidak peduli seberapa jauh jarak di antara keduanya. Kemampuan untuk berada dalam superposisi dan keterbelitan inilah yang memberikan komputer kuantum potensi kekuatan komputasi yang eksponensial.

##### A.2 Gerbang Kuantum Dasar

Operasi pada qubit dilakukan dengan menerapkan serangkaian gerbang kuantum, yang secara matematis direpresentasikan oleh matriks uniter. Gerbang-gerbang ini memanipulasi keadaan qubit, misalnya dengan

memutarnya di dalam ruang keadaan (bola Bloch) atau menciptakan keterbelitan antar-qubit. Beberapa gerbang kuantum dasar yang menjadi fondasi untuk membangun sirkuit kuantum yang lebih kompleks disajikan pada Tabel 2.1.

**Tabel 2.1:** Gerbang kuantum dasar yang umum digunakan.

| Nama Gerbang      | Simbol                                                                              | Matriks                                                                                           | Fungsi                                                                                       |
|-------------------|-------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------|
| Pauli-X (NOT)     |    | $\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$                                                    | Membalik keadaan qubit (mirip gerbang NOT klasik).                                           |
| Pauli-Y           |    | $\begin{pmatrix} 0 & -i \\ i & 0 \end{pmatrix}$                                                   | Melakukan rotasi 180° mengelilingi sumbu Y pada bola Bloch.                                  |
| Pauli-Z           |    | $\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$                                                   | Membalik fasa keadaan $ 1\rangle$ .                                                          |
| Hadamard (H)      |    | $\frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}$                                | Menciptakan superposisi seimbang dari $ 0\rangle$ dan $ 1\rangle$ .                          |
| Phase (P)         |  | $\begin{pmatrix} 1 & 0 \\ 0 & i \end{pmatrix}$                                                    | Melakukan rotasi 90° mengelilingi sumbu Z.                                                   |
| Identity (I)      |  | $\begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$                                                    | Tidak mengubah keadaan qubit (operasi do-nothing).                                           |
| CNOT (CX)         |  | $\begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{pmatrix}$  | Menerapkan gerbang X pada qubit target jika qubit kontrol berada dalam keadaan $ 1\rangle$ . |
| Controlled-Z (CZ) |  | $\begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & -1 \end{pmatrix}$ | Menerapkan gerbang Z pada qubit target jika qubit kontrol berada dalam keadaan $ 1\rangle$ . |

## B. Quantum Machine Learning

*Quantum machine learning* (QML) menawarkan paradigma baru yang berpotensi mengatasi keterbatasan metode klasik. QML berupaya memanfaatkan fenomena mekanika kuantum seperti superposisi, keterkaitan (*entanglement*), dan interferensi untuk meningkatkan

kapabilitas algoritma *machine learning* (ML). Prinsip superposisi memungkinkan sebuah qubit (unit dasar informasi kuantum) untuk merepresentasikan kombinasi dari keadaan  $|0\rangle$  dan  $|1\rangle$  secara bersamaan, sementara *entanglement* menghubungkan keadaan beberapa qubit secara non-lokal. Kemampuan ini secara teoritis memberikan QML kekuatan komputasi yang eksponensial untuk tugas-tugas tertentu dan memungkinkan pemrosesan data dalam jumlah besar serta mengungkap pola kompleks yang sulit atau bahkan tidak mungkin ditemukan oleh komputer klasik.

### C. Support Vector Regression (SVR)

SVR adalah algoritma *supervised learning* yang bertujuan menemukan sebuah fungsi  $f(x)$  yang memiliki deviasi maksimum  $\epsilon$  dari nilai target aktual  $y_i$  untuk semua data latih. Secara matematis, fungsi regresi SVR dapat ditulis sebagai:

$$f(x) = w^T \Phi(x) + b \quad (2.2)$$

di mana  $\Phi(x)$  adalah pemetaan fitur non-linear yang memetakan data input  $x$  ke ruang fitur berdimensi lebih tinggi,  $w$  adalah vektor bobot, dan  $b$  adalah bias. Tujuan optimasi pada fungsi ini adalah meminimalkan kompleksitas model (direpresentasikan oleh  $\frac{1}{2}w^T w$ ) sambil menoleransi galat hingga batas  $\epsilon$ . Masalah optimasi ini dapat diselesaikan melalui bentuk dual yang solusinya bergantung pada fungsi kernel  $K(x_i, x_j) = \Phi(x_i)^T \Phi(x_j)$ .

### D. Model Kuantum Berbasis Kernel


#### D.1 Quantum Feature Map

Langkah fundamental dalam sebagian besar algoritma QML adalah merepresentasikan data klasik ke dalam ruang keadaan kuantum. Proses ini, yang dikenal sebagai *encoding* atau *state preparation*, dilakukan menggunakan sirkuit kuantum yang disebut *quantum feature map*. *Feature map* ini adalah operasi uniter  $U_\Phi(x)$  yang memetakan titik data klasik  $x$  dari ruang fitur  $X$  ke sebuah keadaan kuantum  $|\Phi(x)\rangle$  di ruang Hilbert [12].

Proses ini dimulai dari keadaan awal, biasanya keadaan dasar  $|0\rangle^{\otimes n}$  untuk  $n$  qubit, dan kemudian menerapkan transformasi uniter:

$$|\Phi(x)\rangle = U_{\Phi}(x) |0\rangle^{\otimes n} \quad (2.3)$$

Keadaan kuantum  $|\Phi(x)\rangle$  ini sekarang menjadi representasi data  $x$  dalam fitur kuantum berdimensi tinggi. Salah satu metode encoding yang umum digunakan adalah melalui gerbang rotasi Pauli, di mana fitur-fitur data klasik  $x_i$  digunakan untuk menentukan sudut rotasi  $\theta_i$  pada qubit [24].



**Gambar 2.1:** Representasi visual sirkuit kuantum ZZFeatureMap.

## D.2 Kernel Kuantum

Inti dari metode QSVR adalah kernel kuantum, yang menggantikan fungsi kernel klasik. Kernel kuantum mengukur kemiripan antara dua titik data,  $x_i$  dan  $x_j$ , setelah keduanya dipetakan ke ruang fitur kuantum. Secara matematis, kernel kuantum didefinisikan sebagai kuadrat dari nilai absolut produk dalam (*inner product*) atau *fidelity* antara dua keadaan kuantum yang telah di-encode [12, 24]:

$$k(x_i, x_j) = |\langle \Phi(x_i) | \Phi(x_j) \rangle|^2 \quad (2.4)$$

Nilai kernel ini berkisar dari 0 (untuk keadaan yang saling ortogonal) hingga 1 (untuk keadaan yang identik), sehingga secara efektif menyediakan metrik kesamaan di ruang Hilbert. Untuk melatih model QSVR, sebuah matriks kernel (atau *Gram matrix*)  $K$  perlu dihitung, di mana setiap elemennya adalah  $K_{ij} = k(x_i, x_j)$ .

Untuk mengestimasi nilai kernel ini pada komputer kuantum (atau simulaturnya), salah satu metode yang umum digunakan adalah *inversion test* [16]. Metode ini bekerja dengan menyiapkan sebuah sirkuit kuantum yang pertama-tama menerapkan *feature map*  $U_{\Phi}(x_i)$  dan kemudian menerapkan kebalikannya (invers konjugat) dari *feature map* kedua, yaitu  $U_{\Phi}(x_j)^{\dagger}$ . Nilai kernel kemudian adalah probabilitas untuk mengukur kembali keadaan awal  $|0\rangle^{\otimes n}$ :

$$k(x_i, x_j) = |\langle 0 | U_{\Phi}(x_j)^{\dagger} U_{\Phi}(x_i) | 0 \rangle|^2 \quad (2.5)$$

Dalam praktiknya, probabilitas ini diestimasi dengan menjalankan sirkuit berulang kali dan menghitung frekuensi hasil pengukuran keadaan nol. Setelah seluruh elemen matriks kernel  $K$  diestimasi, matriks ini kemudian dimasukkan ke dalam *solver* SVR klasik untuk menyelesaikan proses optimisasi, yang menggarisbawahi sifat hibrida dari pendekatan *quantum kernel estimation* (QKE) [17].

### D.3 Quantum Support Vector Regression (QSVR)

*Quantum support vector regression* adalah adaptasi kuantum dari algoritma SVR klasik, yang memanfaatkan kernel kuantum untuk memprediksi nilai kontinu. Setelah matriks kernel kuantum  $K$  dihitung, proses optimisasi untuk menemukan *hyperplane* optimal dilakukan secara klasik.

Fungsi untuk titik data baru  $x$  dalam QSVR diberikan oleh persamaan:

$$f(x) = \sum_{i=1}^l (\alpha_i - \alpha_i^*) k(x_i, x) + b \quad (2.6)$$

Di sini,  $\alpha_i$  dan  $\alpha_i^*$  adalah pengganda Lagrange yang diperoleh dari proses pelatihan,  $k(x_i, x)$  adalah kernel kuantum antara data baru dan vektor pendukung (*support vectors*)  $x_i$ , dan  $b$  adalah bias. Keunggulan potensial dari QSVR terletak pada kemampuannya untuk menangkap korelasi non-linear yang kompleks dalam data melalui fitur kuantum berdimensi tinggi [4].

## E. Model Kuantum Berbasis Sirkuit Variasional


### E.1 Quantum Neural Network (QNN)

Sebagai alternatif dari metode kernel, Quantum Neural Network (QNN) menggunakan sirkuit kuantum itu sendiri sebagai model yang dapat dilatih [18]. QNN diimplementasikan sebagai Sirkuit Kuantum Variasional (VQC), di mana data input  $x$  dan parameter terlatih  $\theta$  di-encode ke dalam sirkuit  $U(x, \theta)$ . Output model diperoleh dari nilai ekspektasi sebuah observable  $\hat{M}$  [12, 5]:

$$f_\theta(x) = \langle 0 | U^\dagger(x, \theta) \hat{M} U(x, \theta) | 0 \rangle \quad (2.7)$$

Parameter  $\theta$  kemudian dioptimalkan menggunakan optimizer klasik dalam sebuah loop hibrida untuk meminimalkan fungsi biaya, seperti MSE [19].

Meskipun sangat fleksibel, pelatihan QNN menghadapi tantangan seperti fenomena Barren Plateaus, di mana gradien dapat menghilang secara eksponensial pada sirkuit yang dalam atau acak, sehingga menghambat proses optimisasi [25, 26].



**Gambar 2.2:** Representasi visual QNN.

### E.2 Quantum Long Short-Term Memory (QLSTM)


Untuk menangani data deret waktu secara spesifik, telah dikembangkan arsitektur Quantum Long Short-Term Memory (QLSTM) [20]. Model ini merupakan adaptasi dari arsitektur LSTM klasik yang sangat sukses untuk data sekuensial. Dalam QLSTM, operasi-operasi linear (perkalian matriks) di dalam gerbang-gerbang LSTM seperti forget gate, input gate, dan output gate digantikan oleh sirkuit kuantum variasional (QNN). Tujuannya adalah untuk memanfaatkan ruang komputasi kuantum yang lebih besar untuk menangkap dependensi temporal jangka panjang dengan lebih efektif dan dengan jumlah parameter yang lebih sedikit [20, 27]. Beberapa studi telah berhasil menerapkan QLSTM untuk masalah prakiraan cuaca, termasuk prakiraan curah hujan dan banjir, dan menunjukkan hasil yang menjanjikan [21, 22, 28].

## BAB III

### METODOLOGI PENELITIAN

#### A. Rancangan Penelitian

Penelitian ini dirancang sebagai studi eksperimen komputasi kuantitatif untuk mengevaluasi dan membandingkan secara sistematis performa model machine learning klasik dan kuantum untuk tugas prakiraan curah hujan. Rancangan penelitian ini menggunakan kerangka kerja hibrida kuantum-klasik, di mana komputasi yang menuntut secara klasik (seperti optimisasi) dijalankan di komputer klasik, sementara komputasi inti kuantum (seperti estimasi kernel atau evaluasi sirkuit variasional) dijalankan pada simulator dan divalidasi pada perangkat keras kuantum nyata.



**Gambar 3.1:** Diagram alir rancangan penelitian.

## B. Tempat dan Waktu Penelitian

### B.1 Tempat

Sebagian besar eksperimen komputasi dan analisis data dilakukan dengan memanfaatkan fasilitas komputasi dari *High Performance Computer* (HPC) milik Kelompok Bidang Keahlian (KBK) Fisika Komputasi dan Teoritik, Departemen Fisika, Universitas Negeri Malang. Serta HPC milik Grup Riset Teori Materi Kuantum di Pusat Riset Fisika Kuantum KST BJ Habibi Serpong dan juga menggunakan HPC Mahameru dan HPC GPU Cluster - NVIDIA DGX Badan Riset dan Inovasi Nasional (BRIN), yang berlokasi di Gedung Penginderaan Jauh, KST Soekarno, Cibinong.

### B.2 Waktu

Penelitian ini dilaksanakan dalam kurun waktu 5 bulan, dimulai dari bulan Agustus hingga Desember 2025.

**Tabel 3.1:** Jadwal kegiatan penelitian

| No | Kegiatan                                      | Agu | Sep | Okt | Nov | Des |
|----|-----------------------------------------------|-----|-----|-----|-----|-----|
| 1  | Studi literatur                               |     |     |     |     |     |
| 2  | Prapemrosesan dan eksplorasi data             |     |     |     |     |     |
| 3  | Implementasi model klasik (SVR, ARIMA, LSTM)  |     |     |     |     |     |
| 4  | Implementasi model kuantum (QSVR, QNN, QLSTM) |     |     |     |     |     |
| 5  | Evaluasi & analisis komparatif hasil          |     |     |     |     |     |
| 6  | Penulisan hasil, pembahasan, kesimpulan       |     |     |     |     |     |
| 7  | Pelaporan                                     |     |     |     |     |     |

## C. Prosedur Penelitian


### C.1 Prapemrosesan Data

Tahap pertama dalam prosedur ini adalah akuisisi dan persiapan dataset. Data deret waktu historis diperoleh melalui API dari Copernicus Climate Data Store (CDS) dengan menggunakan dataset *reanalysis-era5-single-levels*. Permintaan data mencakup 8 variabel meteorologi untuk rentang waktu 1 Januari 2020 hingga 31 Desember 2024 dengan resolusi 6 jam dan cakupan area geografis Indonesia [6° LU, 95° BT, -11° LS, 141° BT]. Data mentah yang diperoleh dalam format NetCDF kemudian diolah. Selanjutnya, dilakukan rekayasa fitur untuk mengubah dataset menjadi format *supervised learning*. Vektor fitur input ( $x$ ) dibuat untuk setiap titik data target, yang terdiri dari 8 variabel ERA5 ditambah dengan fitur turunan (fitur lag dari target presipitasi dan fitur temporal), sehingga total menjadi 12 fitur. Variabel target ( $y$ ) yang akan diprediksi adalah total presipitasi (*total precipitation*). Seluruh fitur input dan target kemudian distandarisasi menggunakan *StandardScaler* agar memiliki rata-rata 0 dan varians 1. Terakhir, dataset yang telah diproses dibagi secara kronologis menjadi data latih (80%) dan data uji (20%) untuk menjaga dependensi waktu.

### C.2 Implementasi dan Pelatihan Model

Pada tahap kedua, enam model berbeda diimplementasikan dan dilatih. Tiga model klasik diimplementasikan sebagai *benchmark*, yaitu SVR dengan kernel RBF yang dioptimalkan menggunakan *GridSearchCV*, model statistik ARIMA yang dilatih pada data deret waktu asli, dan jaringan saraf LSTM yang dibangun menggunakan Keras/TensorFlow.

Selanjutnya, tiga model kuantum diimplementasikan. Model QSVR dan QNN sama-sama menggunakan sirkuit *quantum feature map* *ZZFeatureMap* untuk menyandikan data. Sirkuit ini bertugas mengubah vektor fitur klasik menjadi keadaan kuantum melalui serangkaian gerbang rotasi dan CNOT untuk menciptakan keterkaitan (*entanglement*). Representasi visual dari arsitektur sirkuit yang digunakan, misalnya untuk 4 fitur data, diilustrasikan pada Gambar 3.2.



**Gambar 3.2:** Representasi visual sirkuit kuantum ZZFeatureMap. Arsitektur ini digunakan sebagai dasar untuk *quantum feature map* pada model QSVR dan QNN.

Setelah pemetaan fitur, model QSVR dibangun dengan menghitung matriks kernel kuantum menggunakan kelas `FidelityQuantumKernel`, yang kemudian digunakan untuk melatih SVR dengan kernel *precomputed*. Model QNN diimplementasikan sebagai sirkuit kuantum variasional dengan menambahkan *ansatz* `RealAmplitudes` dan dibungkus dalam kelas `NeuralNetworkRegressor`. Terakhir, arsitektur QLSTM diimplementasikan secara konseptual sebagai model hibrida yang menggantikan komponen linear di dalam sel LSTM dengan sirkuit kuantum variasional.

### C.3 Evaluasi dan Analisis Komparatif

Tahap akhir dari penelitian ini adalah evaluasi dan analisis. Keenam model yang telah dilatih digunakan untuk menghasilkan prediksi pada set data uji yang sama. Kinerja prediksi dari setiap model kemudian diukur secara kuantitatif terhadap data aktual menggunakan tiga metrik utama: *Root Mean Squared Error* (RMSE), *Mean Absolute Error* (MAE), dan Koefisien Determinasi ( $R^2$ ). Selain analisis kuantitatif, dilakukan pula analisis kualitatif dengan memvisualisasikan hasil prediksi dalam bentuk plot deret waktu, *scatter plot*, dan plot residual. Terakhir, model-model kuantum terpilih divalidasi dengan menjalankan eksperimen pada perangkat keras kuantum nyata yang tersedia melalui IBM Quantum untuk menganalisis robustitas performa terhadap *noise*. Hasil dari semua evaluasi ini kemudian dibandingkan secara komprehensif untuk menarik kesimpulan mengenai paradigma arsitektur mana yang paling efektif untuk masalah prakiraan curah hujan.

## BIBLIOGRAFI

- [1] B. Surendiran, K. Dhanasekaran, and A. Tamizhselvi. A study on quantum machine learning for accurate and efficient weather prediction. In *2022 Sixth International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud) (I-SMAC)*, 2022.
- [2] Zahra Amiri, Arash Heidari, and Nima Jafari Navimipour. Comprehensive survey of artificial intelligence techniques and strategies for climate change mitigation. *Energy*, 308:132827, 2024.
- [3] Jerald A. Brotzge, Don Berchhoff, DaNa L. Carlis, Frederick H. Carr, Rachel Hogan Carr, Jordan J. Gerth, Brian D. Gross, Thomas M. Hamill, Sue Ellen Haupt, Neil Jacobs, Amy McGovern, David J. Stensrud, Gary Szatkowski, Istvan Szunyogh, and Xuguang Wang. Challenges and opportunities in numerical weather prediction. *Bulletin of the American Meteorological Society*, 104(3):E698–E705, 2023.
- [4] F. Tennie and T. N. Palmer. Quantum computers for weather and climate prediction. *Bulletin of the American Meteorological Society*, 104(2):E488–E503, 2023.
- [5] Ben Jaderberg, Antonio A. Gentile, Atiyo Ghosh, Vincent E. Elfving, Caitlin Jones, Davide Vodola, John Manobianco, and Horst Weiss. Potential of quantum scientific machine learning applied to weather modelling, 2024.
- [6] Riccardo P. Masini, Marcelo C. Medeiros, and Eduardo F. Mendes. Machine learning advances for time series forecasting. *Journal of Economic Surveys*, 37:76–111, 2023.
- [7] Bryan Lim and Stefan Zohren. Time-series forecasting with deep learning: a survey. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 379(2194):20200209, 2021.

- [8] Gaohong Yin, Takao Yoshikane, Kosuke Yamamoto, Takuji Kubota, and Kei Yoshimura. A support vector machine-based method for improving real-time hourly precipitation forecast in japan. *Journal of Hydrology*, 612:128125, 2022.
- [9] Stefan Preda, Simona-Vasilica Oprea, Adela Bâra, and Anda Belciu. Pv forecasting using support vector machine learning in a big data analytics context. *Symmetry*, 10(12):748, 2018.
- [10] Jacob Biamonte, Peter Wittek, Nicola Pancotti, Patrick Rebentrost, Nathan Wiebe, and Seth Lloyd. Quantum machine learning. *Nature*, 549(7671):195–202, 2017.
- [11] Vedran Dunjko and Hans J. Briegel. Machine learning & artificial intelligence in the quantum domain: a review of recent progress. *Reports on Progress in Physics*, 81(7):074001, 2018.
- [12] Maria Schuld and Francesco Petruccione. *Machine Learning with Quantum Computers*. Quantum Science and Technology. Springer, second edition, 2021.
- [13] Vojtech Havlicek, Antonio D. Córcoles, Kristan Temme, Aram W. Harrow, Abhinav Kandala, Jerry M. Chow, and Jay M. Gambetta. Supervised learning with quantum-enhanced feature spaces. *Nature*, 567(7747):209–212, 2019.
- [14] Amira Abbas, David Sutter, Christa Zoufal, Aurelien Lucchi, Alessio Figalli, and Stefan Woerner. The power of quantum neural networks. *Nature Computational Science*, 1(6):403–409, 2021.
- [15] John Preskill. Quantum computing in the nisq era and beyond. *Quantum*, 2:79, 2018.
- [16] Xiaojian Zhou, Jieyao Yu, Junfan Tan, and Ting Jiang. Quantum kernel estimation-based quantum support vector regression. *Quantum Information Processing*, 23(29), 2024.
- [17] Teppei Suzuki, Takashi Hasebe, and Tsubasa Miyazaki. Quantum support vector machines for classification and regression on a trapped-ion quantum computer. *Quantum Machine Intelligence*, 6(31), 2024.

- [18] M. Cerezo, Andrew Arrasmith, Ryan Babbush, Simon C. Benjamin, Suguru Endo, Keisuke Fujii, Jarrod R. McClean, Kosuke Mitarai, Xiao Yuan, Lukasz Cincio, and Patrick J. Coles. Variational quantum algorithms. *Nature Reviews Physics*, 3:625–644, 2021.
- [19] Dimitrios Emmanoulopoulos and Sofija Dimoska. Quantum machine learning in finance: Time series forecasting, 2022.
- [20] Samuel Yen-Chi Chen, Shinjae Yoo, and Yao-Lung L. Fang. Quantum long short-term memory, 2020.
- [21] Saiyam Sakhuja, Shivanshu Siyanwal, Abhishek Tiwari, Britant, and Savita Kashyap. Quantum-assisted machine learning models for enhanced weather prediction, 2025.
- [22] Yumin Dong and Huanxin Ding. Bayesian optimization of hybrid quantum lstm in a mixed model for precipitation forecasting. *Machine Learning: Science and Technology*, 6(1):015065, 2025.
- [23] S. Suhas and S. Divya. Quantum-improved weather forecasting: Integrating quantum machine learning for precise prediction and disaster mitigation. In *2023 International Conference on Quantum Technologies, Communications, Computing, Hardware and Embedded Systems Security (iQ-CCHES)*, 2023.
- [24] Claudio Conti. Quantum mechanics and data-driven physics. In *Quantum Machine Learning*. Springer, 2023.
- [25] Jarrod R. McClean, Sergio Boixo, Vadim N. Smelyanskiy, Ryan Babbush, and Hartmut Neven. Barren plateaus in quantum neural network training landscapes. *Nature Communications*, 9(1):4812, 2018.
- [26] Supanut Thanasilp, Samson Wang, M. Cerezo, and Zoë Holmes. Exponential concentration in quantum kernel methods. *Nature Communications*, 15(5200), 2024.
- [27] Saad Zafar Khan, Nazeefa Muzammil, Salman Ghafoor, Haibat Khan, Syed Mohammad Hassan Zaidi, Abdulah Jeza Aljohani, and Imran Aziz. Quantum long short-term memory (qlstm) vs. classical lstm in time series forecasting: a comparative study in solar power forecasting. *Frontiers in Physics*, 12, 2024.

- [28] Chu-Hsuan Abraham Lin, Chen-Yu Liu, and Kuan-Cheng Chen. Quantum-train long short-term memory: Application on flood prediction problem, 2024.